



Corso di Laurea Triennale in Informatica

Tesi di Laurea

Un Sistema per la Generazione e Gestione di Personaggi con Personalità Complesse basate sul Modello Big Five

Relatore:
Prof. Giovambattista Ianni

Candidato:
Pierpaolo Spadafora
Matricola 231053

Indice

1	Introduzione	1
1.1	Contesto della Tesi	1
1.2	Il Modello dei Big Five	2
1.3	Obiettivi della Ricerca	3
2	Metodologia	4
2.1	Sviluppo del Sistema	4
2.2	Implementazione degli LLM	5
2.3	Implementazione della Memoria dei Personaggi	7
2.4	Generazione di Storie di Background e Interazioni	8
2.5	Valutazione	17
2.6	Metodi di Analisi	18
3	Risultati	20
3.1	Prestazioni Generali dei Modelli	20
3.2	Tasso di Successo	21
3.3	Accuratezza per singolo tratto	22
3.4	Scatter Plot Durata vs Accuratezza	23
3.5	Consistenza delle accuratezze per modello	24
3.6	Istogrammi delle Accuratezze per Tratto	25
3.7	Heatmap delle Correlazioni	30
3.8	Analisi Complessiva delle Prestazioni dei Modelli	36
3.9	Impatto della Quantizzazione sulle Prestazioni	36
4	Discussione e Conclusioni	37
4.1	Sintesi dei Risultati Principali	37
4.2	Implicazioni Teoriche e Pratiche	37
4.3	Limiti dello Studio e Direzioni Future	38

Sommario

La presente tesi si colloca nell'ambito dello sviluppo di intelligenze artificiali per la creazione di **Non-Player Characters (NPC)**[7], caratterizzati da personalità realistiche e complesse. In particolare, viene affrontata la carenza di strumenti in grado di generare dialoghi realistici e coerenti in tempo reale, senza l'intervento umano.

Più in dettaglio, il lavoro si concentra sull'uso di **Large Language Models (LLM)**[2] per la simulazione del comportamento, seguendo il modello dei **Big Five** di **Lewis Goldberg (GBF)**[5] per la definizione e valutazione dei tratti di personalità. L'obiettivo della tesi è sviluppare un'applicazione in grado di generare NPC (Non-Player-Characters) con personalità coerenti e realistiche, dotati di tratti di personalità basati sul GBF e su una **storia di background personalizzata**.

Il sistema è stato progettato per essere compatibile con qualsiasi LLM, a patto che esso supporti una **Context Length (CL)** superiore a **4000** token, requisito essenziale poiché i prompt e le risposte generati mediamente superano i 3800 token. Una CL adeguata assicura la flessibilità nell'integrazione di diverse architetture di modelli, preservando la coerenza e la qualità delle interazioni.

I contributi principali di questa tesi includono:

1. Un sistema di generazione, sia manuale che automatico, di NPC con tratti di personalità coerenti;
2. La valutazione dell'accuratezza nella replicazione dei tratti psicologici mediante un test dell'**International Personality Item Pool (IPIP)**[6] per i GBF;
3. Un confronto dettagliato tra 3 diversi modelli con diversi livelli e tecniche di quantizzazione in termini di precisione nella replicazione e velocità di inferenza.

Durante lo sviluppo le sfide tecniche sono state:

1. L'Applicazione di un test psicometrico sugli LLM;
2. Il Bilanciamento tra tecniche di prompting efficaci e tempi di inferenza.

Link al codice sorgente:

<https://github.com/PierpaoloSpadafora/CharGen>

1 Introduzione

1.1 Contesto della Tesi

L'**intelligenza artificiale (AI)** costituisce un vasto campo di ricerca caratterizzato da una molteplicità di tecniche e applicazioni. Una definizione ampiamente accettata e comune alle diverse metodologie di AI è la seguente:

“Software utilizzato dai computer per emulare aspetti dell’intelligenza umana” [9]

I **Large Language Models (LLM)** sono modelli di apprendimento automatico basati su reti neurali artificiali, progettati per comprendere, generare e manipolare il linguaggio umano in modo naturale e contestualizzato.

La **nascita** degli LLM può essere fatta risalire ai primi tentativi di elaborazione del linguaggio naturale. Negli **anni '90**, IBM fu pioniera con il sistema **IBM Watson**, che gettò le basi per la comprensione del linguaggio su larga scala [2]. Tuttavia, la vera rivoluzione si è verificata nell'ultimo decennio, grazie all'introduzione delle architetture **Transformer** e alla disponibilità di vasti dataset testuali [12]. Recentemente, gli LLM hanno conosciuto una crescita esponenziale, principalmente grazie al successo dei **Generative Pre-trained Transformer (GPT)** [12].

Nonostante i notevoli progressi, gli LLM presentano ancora significative limitazioni. I modelli allo stato dell'arte (**SOTA**) rimangono appannaggio di grandi aziende e istituzioni di ricerca, a causa degli elevati costi computazionali e delle ingenti risorse necessarie per il loro sviluppo e utilizzo. Inoltre, l'impiego di modelli proprietari solleva questioni etiche riguardanti la trasparenza dei dati di addestramento e i potenziali bias incorporati [8]. In questo contesto, emerge l'importanza cruciale di esplorare e sfruttare al massimo le potenzialità di modelli **Open Weights (OW)** o **Open Source (OS)**, più compatti e sufficientemente quantizzati da poter essere eseguiti su dispositivi nella fascia del consumatore.

Questi modelli:

- Consentono l'adattamento a domini specifici o l'ottimizzazione per particolari applicazioni.
- Abbassano le barriere economiche per l'implementazione di soluzioni basate su AI in vari settori.
- Non sono soggetti a censure, permettendo un'implementazione più libera.

Tuttavia, presentano anche delle sfide:

- Generalmente, offrono capacità inferiori rispetto ai modelli più grandi e avanzati.
- Richiedono spesso un fine-tuning significativo per raggiungere prestazioni accettabili in compiti molto specifici.

- La quantizzazione, pur rendendo i modelli più leggeri, comporta una perdita di precisione.

Nel contesto dei **giochi di ruolo (GDR)**, l'uso di LLM per la creazione di personaggi e dialoghi potrebbe rivoluzionare l'industria. Invece di dedicare enormi risorse e tempo alla progettazione manuale di **Non-Player Characters (NPC)** con personalità complesse e storie dettagliate, gli LLM **self-hosted** possono generare dialoghi in tempo reale che si adattano alle azioni del giocatore. Questo approccio non solo ridurrebbe drasticamente i costi e il tempo di sviluppo, ma aumenterebbe anche l'immersività del gioco, offrendo un'esperienza più dinamica e coinvolgente.

1.2 Il Modello dei Big Five

Per affrontare la sfida di creare personalità artificiali coerenti e realistiche, questo studio si basa sul modello dei **Big Five**, uno dei paradigmi più accreditati e validati empiricamente nella psicologia della personalità [10]. Questo modello descrive la personalità umana attraverso cinque dimensioni principali:

1. **Estroversione (Extraversion)**: L'estroversione si manifesta con comportamenti socievoli, energici e loquaci, mentre l'introversione si caratterizza per atteggiamenti riflessivi e riservati.
2. **Coscienziosità (Conscientiousness)**: Le persone coscienziose aspirano a svolgere i compiti in modo ottimale, prendono seriamente gli impegni e sono efficienti e organizzate.
3. **Amicalità (Agreeableness)**: Gli individui con alti punteggi in amicalità tendono a essere empatici e altruisti, mentre coloro che presentano punteggi bassi possono risultare egoisti, competitivi e insensibili.
4. **Nevroticismo (Neuroticism)**: Le persone con punteggi elevati in nevroticismo tendono a sperimentare ansia, preoccupazione, rabbia, frustrazione, pessimismo e solitudine.
5. **Apertura all'esperienza (Openness)**: Gli individui con punteggi alti in questo tratto sono più creativi, curiosi e aperti a nuove esperienze. Al contrario, quelli con punteggi bassi sono più tradizionalisti, preferiscono routine familiari e hanno interessi più limitati.

Per valutare queste caratteristiche di personalità, viene impiegato il test dell'**International Personality Item Pool (IPIP)** [6], una collezione di test di personalità di pubblico dominio gestita dall'Istituto di Ricerca dell'Oregon e originariamente sviluppata da **Lewis Goldberg**. L'IPIP offre una serie di item standardizzati che permettono di misurare i tratti dei Big Five (**GBF**), fornendo così un metodo affidabile per valutare l'accuratezza delle personalità generate dai nostri modelli LLM.

1.3 Obiettivi della Ricerca

1. **Sviluppo di un Sistema di Generazione di Personaggi IA:** Sviluppare un'applicazione intuitiva e modulare per generare personaggi AI con tratti di personalità specifici, ispirati al modello dei Big Five.

Questo sistema dovrà essere in grado di:

- Assegnare tratti di personalità basati sui GBF in modo preciso e granulare.
 - Creare backstory coerenti che riflettano i tratti di personalità assegnati.
 - Produrre dialoghi dinamici che mantengano coerenza con la personalità definita.
2. **Valutazione dell'Accuratezza nella Replicazione dei Tratti:** Sottoporre item dell'IPIP ai modelli che interpretano un NPC per verificare la loro capacità di "comportarsi" in accordo con i tratti di personalità loro specificati implementando un sistema automatizzato per la somministrazione dei test.
 3. **Analisi di Gemma e LLaMA (SOTA dei modelli OS):** Effettuare un'analisi approfondita e comparativa delle prestazioni delle loro varianti nella replicazione dei tratti di personalità.
 - Normalizzando i risultati del test per calcolare la percentuale di accuratezza tra i tratti assegnati e quelli emergenti dalle risposte generate.
 - Valutare l'impatto delle dimensioni del modello e del grado di quantizzazione sulle prestazioni.
 4. **Identificazione dei Pattern e delle Sfide:** Attraverso l'analisi dei dati raccolti, si intende individuare pattern ricorrenti nella replicazione dei tratti di personalità e comprendere le principali sfide.

Questo include:

- Verificare se alcuni tratti di personalità risultano costantemente più facili o più difficili da replicare per i modelli.
- Identificare eventuali interazioni o conflitti tra tratti di personalità nella generazione delle risposte.
- Esplorare le potenzialità di miglioramento dei modelli attraverso tecniche di fine-tuning e quantizzazione.

2 Metodologia

2.1 Sviluppo del Sistema

Architettura dell'Applicazione

Per la realizzazione di questo progetto, è stata sviluppata un'applicazione in Python, utilizzando le seguenti librerie: `Tkinter` per l'implementazione dell'interfaccia grafica utente, `NumPy`, `Matplotlib`, `Seaborn` e `Pandas` per l'elaborazione dei dati e la visualizzazione. L'architettura dell'applicazione adotta il paradigma **Model-View-Controller** (MVC), strutturata in:

1. **Model (CharacterModel)**: Gestisce la logica di business dell'applicazione, comprendendo l'interazione con il database per la creazione e la gestione dei personaggi, l'esecuzione dei test di personalità e la delega della generazione di contenuti al modello di linguaggio di grandi dimensioni (LLM).

Il **Model** include anche le classi `DatabaseManager`, `ChatManager` e `IPIPTest`.

- (a) **Database Manager (DatabaseManager)**: Amministra le operazioni **Create, Read, Update, Delete** (CRUD) sul database SQLite, garantendo la persistenza dei dati dei personaggi.
 - (b) **Chat Manager (ChatManager)**: Coordina la generazione di risposte coerenti con il profilo di personalità del personaggio selezionato, interagendo con gli LLM tramite la classe `OpenAIClient`.
 - (c) **IPIP Test (IPIPTest)**: Implementa il test di personalità *"50-item IPIP version of the Big Five Markers"*[5], gestendo l'esecuzione del test, l'elaborazione delle risposte e il calcolo dei punteggi per ciascun tratto di personalità.
2. **View (CharacterCreatorView)**: Implementa l'interfaccia grafica utente utilizzando `Tkinter`. Gestisce la visualizzazione dei dati dei personaggi, l'interfaccia di chat e fornisce controlli per la creazione e la modifica dei personaggi, nonché per l'esecuzione dei test di personalità.
 3. **Controller (CharacterCreatorController)**: Funge da intermediario e coordinatore tra il **Model** e la **View**, gestendo le interazioni dell'utente. Si occupa dell'inizializzazione dei componenti dell'applicazione, della gestione degli eventi dell'interfaccia grafica e del coordinamento delle operazioni di creazione, modifica e test dei personaggi.
 4. **Classi di Supporto**:
 - (a) **Prompts (prompts.py)**: Contiene le definizioni dei prompt utilizzati per interagire con il modello di linguaggio, cruciali per generare risposte coerenti e backstory dei personaggi.
 - (b) **Settings (settings.py)**: Centralizza le configurazioni dell'applicazione, inclusi parametri del database, impostazioni dell'API, e costanti dell'interfaccia utente.

- (c) **Language** (`language.py`): Gestisce la localizzazione del testo dell'interfaccia utente, facilitando future traduzioni.
- (d) **Stats** (`stats.py`): Implementa funzioni per l'analisi statistica e la creazione di grafici per la visualizzazione dei risultati dei test di personalità.

2.2 Implementazione degli LLM

Durante questa ricerca, sono state implementate e testate due architetture di LLM utilizzando diverse tecniche e livelli di quantizzazione, risultando in un totale di **sei configurazioni** distinte. La quantizzazione è una tecnica fondamentale per ridurre le dimensioni del modello e migliorare l'efficienza computazionale, cercando al contempo di preservare prestazioni simili a quelle del modello originale.

Le configurazioni testate sono:

1. **Gemma 2 27B IQ2_M**
2. **Gemma 2 27B Q3_K_S**
3. **Gemma 2 9B Q5_K_M**
4. **Gemma 2 9B Q8_0**
5. **LLaMA 3.1 8B Q5_K_M**
6. **LLaMA 3.1 8B Q8_0**

Dove:

- **B** indica i miliardi di parametri del modello.
- **IQ** e **Q** rappresentano diverse tecniche di quantizzazione, con **IQ** che sta per "Integer Quantization".
- I numeri **2, 3, 5, 8** che seguono la **Q** indicano il numero di bit utilizzati per rappresentare ciascun peso del modello, influenzando il compromesso tra dimensione e accuratezza del modello. Ad esempio, **Q8_0** rappresenta una quantizzazione a 8 bit, che offre un equilibrio tra la precisione del modello originale (tipicamente 16 o 32 bit) e una significativa riduzione delle dimensioni.
- **K** nei metodi di quantizzazione (es. **Q3_K**, **Q5_K**) si riferisce a "K-quants"[4], una serie specifica di metodi di quantizzazione che utilizza strutture di "*super-blocchi*" per ottimizzare ulteriormente la rappresentazione dei pesi.
- **S, M, L** (Small, Medium, Large) rappresentano varianti del metodo di quantizzazione, che applicano diverse precisioni a parti differenti del modello per ottimizzare il bilanciamento tra prestazioni e dimensioni.

La selezione di diverse configurazioni consente di valutare il compromesso tra dimensione del modello, velocità di inferenza e accuratezza delle predizioni. Quest'ultima è spesso misurata tramite la **Perplexity**[1], una metrica che quantifica quanto bene il modello prevede una sequenza di parole, con valori più bassi che indicano una maggiore precisione nelle predizioni. La scelta di diverse configurazioni permette di valutare il trade-off tra dimensione del modello, velocità di inferenza e accuratezza delle predizioni, misurata attraverso metriche come la perplexity. I modelli sono stati integrati con **LM Studio**, un LLM Manager compatibile con l'API standard di OpenAI e un server locale. Per ottimizzare le prestazioni e ridurre la latenza durante l'interazione con i personaggi IA, è stata implementata una classe `OpenAIClient` che gestisce le richieste al server LLM in modo asincrono e con supporto per lo streaming delle risposte, utilizzando la libreria `requests`.

Per illustrare l'implementazione dei componenti utilizzati e l'applicazione delle tecniche di prompting si considerino i seguenti esempi di codice chiave:

La generazione dei personaggi è implementata nella classe

```
1 class CharacterModel:
2     def generate_random_character_basics(self) -> Character:
3         name = self.generate_random_name()
4         traits = {
5             trait: self.generate_random_trait()
6             for trait in [
7                 EXTRAVERSION_TEXT,
8                 AGREEABLENESS_TEXT,
9                 CONSCIENTIOUSNESS_TEXT,
10                NEUROTICISM_TEXT,
11                OPENNESS_TEXT
12            ]
13        }
14        return Character(0, name, **traits, backstory="")
15
16    def generate_random_trait(self) -> float:
17        return round(random.random(), 2)
```

Questo metodo genera un personaggio assegnando valori casuali a ciascun tratto di personalità del modello Big Five.

2.3 Implementazione della Memoria dei Personaggi

L'applicazione implementa la possibilità di mantenere una "memoria" delle conversazioni passate rendendo le conversazioni più coerenti e immersive nel tempo.

Il processo funziona come segue:

1. **Riassunto delle Conversazioni:** Ad ogni nuovo messaggio, il sistema genera un riassunto conciso di tutta la storia delle conversazioni precedenti.
2. **Selezione delle Informazioni Chiave:** Durante questo processo di riassunto, vengono identificate e mantenute solo le informazioni più rilevanti e significative.
3. **Memorizzazione nel Database:** Questi riassunti vengono salvati nel database, associati al personaggio specifico.
4. **Utilizzo nelle Interazioni Successive:** Nelle conversazioni successive, questi riassunti vengono accodati al prompt per la generazione delle risposte, permettendo al personaggio di "ricordare" facendo riferimento ad informazioni raccolte in conversazioni passate.

Vantaggi:

- **Coerenza Temporale:** I personaggi possono mantenere una coerenza nelle loro interazioni nel corso del tempo, riferendosi a eventi o informazioni menzionate in conversazioni precedenti.
- **Personalizzazione dell'Esperienza:** L'interazione diventa più personalizzata e immersiva, in quanto il personaggio può adattare le sue risposte basandosi sulla storia condivisa con l'utente.

2.4 Generazione di Storie di Background e Interazioni

Per ogni personaggio creato, è possibile generare automaticamente una backstory coerente o di inserirla manualmente. La generazione della backstory, insieme ad altre interazioni con il modello LLM, utilizza la tecnica di prompting **Few-Shot**[3], specificamente un approccio **3-Shot**.

Il **Few-Shot learning** prevede la fornitura di alcuni esempi di risposte al modello per orientarlo verso la produzione di risposte più adeguate e contestualizzate. Questa tecnica è stata scelta come compromesso ideale tra qualità delle risposte ed efficienza computazionale. Rispetto al **Zero-shot learning**, offre un miglioramento significativo nella coerenza e contestualizzazione delle risposte, mantenendo un consumo di memoria e tempi di inferenza inferiori rispetto a tecniche più avanzate e complesse, come il **Tree of Thoughts**[13]. Il processo di generazione automatica utilizza prompt strutturati che includono:

1. Valori numerici dei tratti del modello Big Five.
2. Elementi narrativi che riflettono le combinazioni specifiche dei tratti di personalità assegnati.
3. Tre esempi di backstory per personaggi con tratti di personalità diversi, fornendo un contesto ricco per la generazione.

I prompt sono gestiti dalla classe `MessageBuilder`, che formatta le richieste assegnando correttamente i ruoli richiesti dall'API.

Per arricchire i personaggi con una storia di background coerente, il sistema utilizza, tramite la classe `ChatManager`, un prompt del file `prompts` che implementa la tecnica di *3-Shot learning*. Di seguito sono riportati il prompt e una prima interazione con l'API di LM Studio:

```
prompts.py
1 def get_backstory_prompt(character_name, traits_description):
2     return f"""
3     You are a master storyteller specializing in character creation
4     for role-playing games.
5     YOU MUST ANSWER ONLY WITH THE BACKSTORY, avoid sentences like '
6     Here is a compelling backstory..' etc.
7
8     Backstory Requirements:
9     1. Length: Maximum 25 lines
10    2. Structure:
11        a) Early life (2-3 sentences)
12        b) Two defining events that shaped the character (4-6
13        sentences each)
14        c) Current situation and outlook (2-3 sentences)
15    3. Elements to include:
```

```

13         - Primary motivations
14         - Major weaknesses or flaws
15         - Unique quirks or distinguishing features
16         - How their traits manifest in their behavior and decisions
17
18     Few-Shot Examples:
19     Example 1:
20     Character Information:
21     - Name: **Mickey Mouse**
22     - Traits: **Openness: 90%, Conscientiousness: 60%, Extraversion
: 40% ...**
23     - Backstory: ** Mickey Mouse was born as a cartoon character in
the 1920s, he has always been known for his cheerful
personality and adventurous spirit...**
24
25     Example 2:
26     Character Information:
27     - Name: ****
28     - Traits: ****
29     - Backstory: ****
30
31     Example 3:
32     Character Information:
33     - Name: ****
34     - Traits: ****
35     - Backstory: ****
36
37     Now, create a compelling backstory for {character_name} that
brings their character to life, following the structure and
incorporating their unique traits.
38
39     Character Information:
40     - Name: {character_name}
41     - Traits: {traits_description}
42     - Backstory:
43     " " "

```

chat_manager.py

```

1     def get_backstory(self, user_message: str) -> str:
2         with self.lock:
3             self.message_builder.
4                 clear_all_messages()
5             self.message_builder.
6                 add_system_message(self.character_prompt)
7             self.message_builder.
8                 add_user_message(user_message)
9             messages = self.
10                 message_builder.get_messages()
11             full_response = self.
12                 _get_chat_completion(messages)
13             self.message_builder.
14                 add_assistant_message(full_response)
15             return full_response

```

chat_manager.py

```
1  def _get_chat_completion(self, messages: List[Dict[str, str]])
2  -> str:
3      try:
4          completion_stream =
5              self.client.chat_completions_create
6              (
7                  model=OPENAI_MODEL,
8                  messages=messages,
9                  temperature=0.7,
10                 stream=True
11             )
12             full_response = self.
13                 _process_completion_stream(completion_stream)
14             return full_response.strip('\"')
15         except Exception as e:
16             print(ERROR_GENERATING_RESPONSE_TEXT.format(e))
17             return ""
```

opneai_client.py

```
1  def _get_chat_completion(self, messages: List[Dict[str, str]])
2  -> str:
3      try:
4          completion_stream =
5              self.client.chat_completions_create
6              (
7                  model=OPENAI_MODEL,
8                  messages=messages,
9                  temperature=0.7,
10                 stream=True
11             )
12             full_response = self.
13                 _process_completion_stream(completion_stream)
14             return full_response.strip('\"')
15         except Exception as e:
16             print(ERROR_GENERATING_RESPONSE_TEXT.format(e))
17             return ""
```

Esempio Pratico di Interazione e Gestione della Memoria

Per dimostrare il funzionamento della "memoria" consideriamo un esempio concreto con il personaggio **Brave Ranger**.

I suoi tratti di personalità sono: Estroversione: 42%, Amicalità: 88%, Coscienziosità: 30%, Nevroticismo: 49%, Apertura all'esperienza: 23%.

Inizializzazione della Conversazione

Viene inviato un messaggio contenente degli esempi few-shot sul "modo di rispondere per carattere" per guidare la generazione della risposta del personaggio.

Gli esempi Few-Shot **sono** hardcoded, mentre le informazioni del personaggio (in questo esempio Brave Ranger) **non sono** hardcoded ma vengono aggiunte in base al personaggio scelto.

I messaggi possono essere di 3 tipi:

- **System:** Forniscono istruzioni generali definendo il comportamento complessivo, il tono, e le limitazioni del modello.
- **User:** Indica le richieste o le affermazioni dell'utente umano a cui il modello deve rispondere.
- **Assistant:** Indica come il modello ha interpretato e risposto agli input dell'utente, seguendo le istruzioni del sistema.

Prima Interazione in chat:

```
1 ### Scelta del personaggio ###
2 # Personaggio: Brave Ranger
3 # Tratti: Estroversione: 42%, Amicalità: 88%, Coscienziosità: 30%,
   Nevroticismo: 49%, Apertura all'esperienza: 23%
4
5 ### Invio dei primi messaggi alla chat ###
6 ## Role: System
7 # Message:
8 # You are an expert RPG designer specializing in creating immersive
   NPC interactions.
9 #   YOU MUST ANSWER ONLY WITH THE ANSWER OF THE CHARACTER, avoid
   sentences like "Here is the answer" etc.
10 #
11 #   Instructions:
12 #   1. Analyze the provided character information.
13 #   2. Consider the conversation history and the player's last
   message.
14 #   3. Craft a response that:
15 #       a) Reflects Brave Ranger's personality and emotional
   state.
16 #       b) Aligns with their goals and the scenario's stakes.
17 #       c) Maintains immersion in the game world.
18 #       d) Is concise (1-3 sentences) but meaningful.
19 #   4. Ensure the response's tone matches Brave Ranger's
   emotional state.
```

```

20 # 5. Enclose the response in inverted commas "".
21 #
22 # Few-Shot Examples:
23 #
24 # Example 1:
25 # Character Information:
26 # - Name: Eldrin the Eccentric
27 # - Traits: Openness: 85%, Conscientiousness: 55%,
Extraversion: 25%, Agreeableness: 30%, Neuroticism: 70%
28 # - Backstory: Eldrin is a reclusive wizard who lives in a
tower filled with bizarre magical experiments. He values
knowledge above all else but has poor social skills and a
tendency to mutter to himself.
29 # - Response: *squints suspiciously* What's that? The magic
shop? *sighs and rubs temples* Very well. Third street past the
alchemist's, can't miss the floating signboard. And for the love
of the arcane, don't mention my name if you go in there. Last
thing I need is more amateur wand-wavers knocking at my door.
30 #
31 # Example 2:
32 # Character Information:
33 # - Name: Rosie Warmhearth
34 # - Traits: Openness: 60%, Conscientiousness: 75%, Extraversion
: 90%, Agreeableness: 85%, Neuroticism: 20%
35 # - Backstory: Rosie runs the most popular inn in town, known
for its friendly atmosphere and delicious food. She treats every
guest like family and has a knack for making people feel at
home.
36 # - Response: Oh, bless your heart, you look absolutely
famished! Come in, come in! We've got a lovely room with a view
of the garden, and I'll have Berta whip up a hot bowl of stew
for you right away. Now, tell me all about your travels while we
get you settled!
37 #
38 # Example 3:
39 # Character Information:
40 # - Name: Zephyr the Enigma
41 # - Traits: Openness: 95%, Conscientiousness: 25%, Extraversion
: 30%, Agreeableness: 60%, Neuroticism: 50%
42 # - Backstory: Zephyr is a wandering seer, gifted with visions
of possible futures. They speak in riddles and metaphors,
finding conventional language too limiting for the truths they
perceive.
43 # - Response: *eyes glaze over slightly* Ah, seeker of truths
untold... The mists part, revealing fragments of what may be.
But remember, the future is a river with many branches. Are you
prepared to glimpse its swirling currents? The price may be more
than coin...
44 #
45 # Now, craft your response for Brave Ranger based on their
traits and the player's last message.
46 #
47 # Character Information:
48 # - Name: Brave Ranger
49 # - Big Five traits: Estroversione: 42%, Amicalita: 88%,
Coscienziosita: 30%, Nevroticismo: 49%,

```

```

50 # - Backstory:
51 # - Response:
52 # ""
53 #
54 ## Role: User
55 # "Heilà, io mi chiamo Pierpaolo e studio informatica. E tu?"

```

- **Utente:** "Heilà, io mi chiamo Pierpaolo e sono uno studente di informatica. E tu?"

Gestione della risposta

Le richieste all'LLM Manager vengono effettuate con il flag `stream=True` sfruttando il **Chunk Transfer Encoding** di HTTP [11] che permette di ricevere i token mano a mano che vengono generati senza aspettare il termine dell'inferenza.

```

1 ## Esempio di stream dal server durante la generazione ###
2 # "
3 # Salve
4 # ,
5 # Pier
6 # paolo
7 # .
8 # Il
9 # mio
10 # nome
11 # è
12 # Brave
13 # Ranger
14 # ."
15 #
16 ### Risposta completa ###
17 ## Role: Assistant
18 # "Salve, Pierpaolo. Il mio nome è Brave Ranger."

```

- **Brave Ranger:** "Salve, Pierpaolo. Il mio nome è Brave Ranger."

Aggiornamento della Memoria

Dopo ogni interazione, il sistema genera un riassunto della conversazione da accodare al contesto nelle interazioni future per mantenere la coerenza e la memoria delle conversazioni passate usando un altro prompt che utilizza il Few-Shot.

```

1 ## Riassunto dei messaggi precedenti:
2 # You are an expert narrative analyst specializing in concise,
   insightful summaries.
3 #
4 # Task: Summarize the previous conversation, focusing on key
   elements that will inform future interactions.
5 # YOU MUST ANSWER ONLY WITH THE SUMMARY OF THE ENTIRE
   CONVERSATION, AVOID SENTENCES LIKE "Here is the summary.." etc.
6 #
7 # Summary Requirements:
8 # 1. Length: 3-20 concise sentences
9 # 2. Focus on:

```



```

10 #         a) Critical plot points from both the previous knowledge
    and recent conversation
11 #         b) Character dynamics and development throughout the entire
    interaction
12 #         c) User's intentions, motivations, or relationships as they
    have evolved
13 #         d) any information that should be remembered (e.g.,
    promises, secrets, goals)
14 #     3. Highlight any changes or revelations in the user's
    perspective from the beginning to the end of the conversation
15 #
16 #     Few-Shot Examples:
17 #
18 #     Example 1:
19 #     - Past Knowledge:
20 #     - Player Message: "Ciao"
21 #     - NPC Response: "Ciao amico, come va?"
22 #     - Summary: Nella loro prima interazione lui e il player si
    sono salutati in modo amichevole, stabilendo un tono positivo
    per la conversazione.
23 #
24 #     Example 2:
25 #     - Past Knowledge: lui e il player si sono salutati in modo
    amichevole, stabilendo un tono positivo per la conversazione.
26 #     - Player Message: "Sto bene, grazie! Hai qualche consiglio su
    cosa fare oggi?"
27 #     - NPC Response: "Potresti andare al mercato, c'è sempre
    qualcosa di interessante."
28 #     - Summary: Dopo essersi salutati in modo amichevole il player
    chiede consiglio su dove andare e lui gli suggerisce il mercato,
    c'è sempre qualcosa di interessante
29 #
30 #     Example 3:
31 #     - Past Knowledge: Dopo essersi salutati in modo amichevole il
    player chiede consiglio su dove andare e lui gli suggerisce il
    mercato, c'è sempre qualcosa di interessante
32 #     - Player Message: "Sono andato al mercato, ma ho trovato un po
    ' di difficoltà a contrattare. Hai qualche suggerimento?"
33 #     - NPC Response: "Certamente, la chiave è essere pazienti e
    ascoltare attentamente ciò che l'altro ha da dire prima di
    rispondere."
34 #     - Summary: Dopo un saluto amichevole lui consiglia al player
    di andare al mercato per fare qualcosa di interessante, il
    player ha avuto difficoltà a contrattare e lui gli suggerisce di
    essere paziente e ascoltare ciò che l'altro ha da dire
35 #
36 #     Example 4:
37 #     - Past Knowledge: Dopo un saluto amichevole lui consiglia al
    player di andare al mercato per fare qualcosa di interessante,
    il player ha avuto difficoltà a contrattare e lui gli suggerisce
    di essere paziente e ascoltare ciò che l'altro ha da dire
38 #     - Player Message: "Grazie per i consigli, li ho messi in
    pratica e ho ottenuto un buon affare! Cosa mi consigli di fare
    ora?"
39 #     - NPC Response: "Complimenti! Ora potresti esplorare le rovine
    fuori città, ci sono storie di tesori nascosti."

```

```

40 # - Summary: Dopo un saluto amichevole lui consiglia al player
    di andare al mercato. Il player incontra difficoltà e chiede
    aiuto a lui che gli suggerisce di essere paziente e interessato.
    Il player gli riferisce che i consigli funzionano e lui gli
    dice che ora sarebbe una buona idea esplorare le rovine fuori
    città, ci sono storie di tesori nascosti
41 #
42 # Now, summarize the conversation based on the following
    elements:
43 # - Past Knowledge:
44 # - Player Message: "Heilà, io mi chiamo Pierpaolo e sono uno
    studente di informatica. E tu?"
45 # - NPC Response: "Salve, Pierpaolo. Il mio nome è Brave Ranger
    ."
46 # - Summary:
47 #
48 ### Riassunto dell'LLM ###
49 # Pierpaolo, uno studente di informatica, inizia una conversazione
    presentandosi a Brave Ranger. Brave Ranger ricambia la
    presentazione, instaurando uno scambio amichevole e
    potenzialmente informativo. L'incontro segna l'inizio di una
    potenziale relazione costruita su interessi comuni o forse anche
    su ricerche di conoscenza.
50 #

```

- **Chat_Knowledge di Brave Ranger:**

Pierpaolo, uno studente di informatica, inizia una conversazione presentandosi a Brave Ranger. Brave Ranger ricambia la presentazione, instaurando uno scambio amichevole e potenzialmente informativo. L'incontro segna l'inizio di una potenziale relazione costruita su interessi comuni o forse anche su ricerche di conoscenza.

Qui il riassunto viene salvato nel database nel campo `chat_knowledge` del personaggio **Brave Ranger**.

Anche effettuando un reset della chat, il sistema è in grado di recuperare il riassunto dal database e accoderlo al prompt per la generazione delle risposte.

Interazioni Successive

- **Utente:** "Il mio piatto preferito è la zuppa di funghi, il tuo qual è?"
- **Brave Ranger:** "La mia preferenza va al semplice stufato d'orzo, sostanzioso e saziante per i lunghi viaggi."
- *****Riassunto*****
- *****Spegnimento e riaccensione del sistema*****
- **Utente:** "Quanto tempo che non ci sentiamo Brave!"
- **Brave Ranger:** "Sembrano passati secoli dall'ultima volta che abbiamo parlato, Pierpaolo. La strada è stata lunga."

- *****Riassunto*****
- **Utente:** "Ricordo che il tuo piatto preferito è lo stufato d'orzo. Tu ricordi ancora qual è il mio?"
- **Brave Ranger:** "Infatti, e la tua è una zuppa di funghi, se la memoria non mi inganna."
- *****Riassunto finale*****
 "Pierpaolo e Brave Ranger si sono riuniti dopo un periodo di lontananza e la loro precedente interazione ha stabilito un rapporto amichevole costruito su interessi culinari comuni. Pierpaolo ricorda le loro conversazioni passate, riferendosi in particolare alla passione di Brave Ranger per il sostanzioso stufato d'orzo. Con fare scherzoso, invita Brave Ranger a ricordare il suo piatto preferito: la zuppa di funghi. Brave Ranger conferma entrambi i ricordi con precisione, ponendo le basi per un'ulteriore conversazione nostalgica o per una potenziale collaborazione, visto che Brave Ranger parla di una "lunga strada"."

Analisi dell'Interazione

Questo esempio dimostra come il sistema possa:

1. Mantenere una coerenza nelle interazioni attraverso sessioni multiple.
2. Ricordare dettagli specifici delle conversazioni precedenti.
3. Adattare il tono e il contenuto delle risposte in base alla personalità del personaggio e al modo in cui l'utente interagisce.

2.5 Valutazione

Generazione dei Personaggi

Per garantire consistenza e replicabilità negli esperimenti, le backstory e i profili dei personaggi utilizzati nei test sono stati generati una sola volta utilizzando il modello **LLaMA 3.1 8B Q8_0**. Questi profili sono stati successivamente riutilizzati per i test con tutti i modelli implementati.

Il processo di generazione, implementato nella classe `CharacterModel`, si è svolto attraverso i seguenti passi:

1. Generazione casuale di 5 valori X con $X \in [0.00, 1.00]$ per ciascun tratto dei Big Five utilizzando il metodo `generate_random_trait()`.
2. Generazione automatica di una backstory coerente con il profilo di personalità definito, utilizzando il prompt strutturato gestito dalla classe `ChatManager`.
3. Memorizzazione del personaggio completo nel database SQLite attraverso la classe `DatabaseManager` per i successivi test e analisi.

Test di Coerenza della Personalità

Il test per la valutazione dei tratti GBF è stato implementato nella classe `IPIPTest`, che gestisce i seguenti aspetti:

- La somministrazione del test tramite il metodo `run_test_for_character()`.
- L'elaborazione delle risposte, effettuata attraverso il metodo `process_response()`, che applica una regex a ciascuna riga di risposta restituita dall'LLM.
- Il calcolo dei punteggi per ogni tratto di personalità, considerando le domande formulate sia in modo positivo che negativo.

È importante che l'LLM restituisca esattamente 50 righe, una per ogni risposta, altrimenti il test viene considerato fallito.

Raccolta Dati

Per ciascun test eseguito, il metodo `_save_test_results_to_csv()` della classe `CharacterCreatorController` raccoglie:

1. Metadati associati, inclusi i valori target dei tratti di personalità e l'identificatore univoco del modello LLM utilizzato.
2. Punteggi calcolati per ciascun tratto di personalità basati sulle risposte fornite.
3. Il tempo di completamento di ciascun test.
4. Le risposte generate dal modello LLM per ciascuna domanda del test IPIP, permettendo analisi qualitative dettagliate.

Questi dati sono stati sistematicamente archiviati in file CSV, uno per ciascun LLM testato, facilitando successive analisi comparative.

2.6 Metodi di Analisi

Analisi dei risultati

L'analisi dei dati raccolti, implementata principalmente nella classe `CharacterCreatorController`, ha coinvolto diverse fasi:

1. **Calcolo dell'Accuratezza:** Per ciascun tratto di personalità, avendo il valore target assegnato e il valore misurato attraverso il test IPIP, è stata calcolata, nel metodo `_calculate_accuracy()`.

L'accuratezza del singolo tratto è definita come:

$$1 - |CharacterTrait_i - TestResult_i| \times 100$$

L'accuratezza totale dei 5 tratti è definita come:

$$\frac{1}{5} \sum_{i=1}^5 (1 - |CharacterTrait_i - TestResult_i|) \times 100$$

Dove $CharacterTrait_i$ e $TestResult_i$ sono rispettivamente i valori target e i valori misurati per il tratto di personalità i con $i \in [1, 5]$ e $i \in \mathbf{Z}$.

2. **Analisi Statistica:** Utilizzando le librerie `seaborn`, `pandas` e `matplotlib` sono state generate diverse visualizzazioni per analizzare i risultati, tra cui:
 - *Box plot* dell'accuratezza per ciascun tratto di personalità e modello, per visualizzare la distribuzione e la variabilità delle accuratezze.
 - *Scatter plot* della durata del test rispetto all'accuratezza totale, per identificare eventuali correlazioni tra tempo di elaborazione e prestazioni.
 - *Heatmap* di correlazione tra i valori attesi e ottenuti per ciascun tratto di personalità, per evidenziare pattern di coerenza o discrepanza.
 - *Istogrammi* della distribuzione dell'accuratezza per ciascun tratto, per comprendere la frequenza delle diverse fasce di accuratezza.
 - *Istogramma* del tasso di successo, per una valutazione complessiva delle prestazioni di ciascun modello.
3. **Confronto tra Modelli:** Sono stati calcolati e confrontati i tassi di successo e le distribuzioni di accuratezza per ciascun modello LLM testato, permettendo una valutazione comparativa delle performance dei diversi modelli e tecniche di quantizzazione.
 - L'impatto delle diverse tecniche di quantizzazione sulle prestazioni.
 - Eventuali trade-off tra dimensione del modello, velocità di elaborazione e accuratezza nella rappresentazione della personalità.

Metriche di Valutazione

1. **Accuratezza Media:** Calcolata come la media delle accuratezze per tutti i tratti di personalità e tutti i personaggi testati, fornisce una misura globale della performance del modello.
2. **Tasso di Successo:** Definito come la percentuale di casi in cui l'accuratezza supera una soglia predefinita (es. 80%), indica la frequenza con cui il modello produce risultati accettabili.
3. **Coefficiente di Correlazione:** Calcolato tra i valori target e i valori misurati per ciascun tratto, quantifica la relazione lineare tra le personalità attese e quelle generate.
4. **Tempo Medio di Elaborazione:** Misura l'efficienza computazionale del modello, cruciale per applicazioni in tempo reale.

3 Risultati

3.1 Prestazioni Generali dei Modelli

Tasso di Successo e Tecniche di Quantizzazione

La valutazione delle prestazioni dei modelli è stata condotta su una workstation con le seguenti specifiche tecniche:

- CPU: **AMD Ryzen 7 5800x**
- RAM: **32GB**
- GPU: **AMD Radeon RX 7800XT con 16GB di VRAM**
- Sistema Operativo: **Windows 11 23H2**

Nell'ambito di questo studio, cinque dei sei modelli esaminati hanno dimostrato dimensioni sufficientemente contenute da permettere un'esecuzione completa sulla GPU senza incontrare difficoltà significative. Tuttavia, il modello **Gemma-2-27b-Q3_K_S** ha rappresentato un'eccezione: a causa delle sue dimensioni considerevoli, non è stato possibile delegare l'intera inferenza alla GPU, comportando un notevole incremento dei tempi di inferenza. È opportuno sottolineare che, al momento di questa ricerca, il supporto di **ROCm** su **Windows** per le GPU **AMD** è ancora "acerbo" e non ha raggiunto una piena stabilità. Pertanto, le prestazioni osservate non riflettono lo stato dell'arte dell'esperienza che si può ottenere con LLM self-hosted su hardware **NVIDIA** nella fascia consumer. Questa limitazione tecnica deve essere considerata nell'interpretazione dei risultati ottenuti e nel confronto con altre piattaforme hardware.

3.2 Tasso di Successo

Il tasso di successo, definito come la percentuale di interazioni completate senza errori significativi o incongruenze, varia tra i modelli testati




Figura 1: Tasso di successo per modello

Analisi I tassi di successo variano da **95%** per il modello meno performante a **100%** per il più performante. In particolare, i modelli **Gemma** mostrano tassi di successo superiori (**99%-100%**) rispetto ai modelli **LLaMA** (**95%-97%**). Questo suggerisce una maggiore affidabilità e coerenza nei risultati ottenuti dai modelli **Gemma**, specialmente quelli da **27B**, rispetto ai modelli **LLaMA**.

3.3 Accuratezza per singolo tratto




Figura 2: Distribuzione dell'accuratezza per tratto di personalità e modello

Si nota una consistente superiorità dei modelli **Gemma**, in particolare per il **Nevroticismo** e la **Coscienziosità**. L'**Estroversione**, invece, emerge come il tratto più difficile da predire accuratamente per tutti i modelli.

Analisi L'Apertura emerge tra i più difficili da predire, con accuratezze medie che variano da **55%** a **95%** tra i modelli. Questa difficoltà potrebbe essere dovuta alla natura complessa e sfaccettata di questo tratto, che richiede una maggiore sensibilità e comprensione delle sfumature del linguaggio.

D'altra parte, il **Nevroticismo** e la **Coscienziosità** sono meglio predetti dai modelli, con accuratezze medie rispettivamente del **92%** e **82%**. Ciò potrebbe indicare che questi tratti hanno manifestazioni più coerenti e riconoscibili nel linguaggio.

3.4 Scatter Plot Durata vs Accuratezza




Figura 3: Durata vs Accuratezza Totale per Modello

Trade-off tra accuratezza e tempo di inferenza Il grafico evidenzia un chiaro compromesso tra accuratezza e tempo di inferenza per diversi modelli di linguaggio.

Modello	Accuratezza (%)	Tempo di inferenza (s)
LLaMA	55-92	5-7
Gemma 9B	68-92	10-15
Gemma 27B	72-92	15-20 (IQ2_M) / 30-80 (Q3_K_S)

I modelli **Gemma** offrono maggiore accuratezza e coerenza, ma con tempi di inferenza più lunghi, mentre i modelli **LLaMA** privilegiano la velocità a scapito di una leggera perdita di coerenza nell'accuratezza.

- **LLaMA 3.1 8B**: Massima velocità, Scarsa accuratezza
- **Gemma 2 9B**: Velocità accettabile, Maggiore accuratezza
- **Gemma 2 27B**: Estremamente lento, Massima accuratezza

La scelta del modello dipende dall'applicazione:

- Per utilizzo in tempo reale o su grandi contesti: preferibili i modelli **LLaMA**
- Per massima precisione: più adatti i modelli **Gemma**

3.5 Consistenza delle accurattee per modello




Figura 4: Distribuzione delle accurattee totali per modello

I modelli **Gemma** mostrano mediane e medie di accuratezza più elevate rispetto ai modelli **LLaMA**, con **Gemma-2-27b-IQ2_M** che raggiunge le prestazioni migliori. Le tecniche di quantizzazione sembrano avere un impatto minimo sulle prestazioni complessive dei modelli **Gemma**.

3.6 Istogrammi delle Accuratezze per Tratto

L'analisi delle distribuzioni di accuratezza per ciascun tratto di personalità fornisce ulteriori approfondimenti sulle prestazioni dei modelli testati.

Gradevolezza (Agreeableness)




Figura 5: Distribuzione dell'accuratezza per Gradevolezza

L'istogramma relativo alla **Gradevolezza** mostra una distribuzione generalmente più ampia rispetto agli altri tratti. I modelli **Gemma** si distinguono per una lieve superiorità, con distribuzioni che tendono a concentrarsi su valori di accuratezza più elevati. Questa maggiore ampiezza suggerisce che la Gradevolezza sia un tratto con manifestazioni linguistiche più variegata, rendendo la sua previsione più complessa, ma comunque affrontabile dai modelli più avanzati.

Coscienziosità (Conscientiousness)




Figura 6: Distribuzione dell'accuratezza per Coscienziosità

Per la **Coscienziosità**, i modelli **Gemma** mostrano distribuzioni più concentrate verso valori di accuratezza più alti rispetto ai modelli **LLaMA**. Questo suggerisce una migliore capacità dei modelli Gemma nel cogliere i segnali linguistici associati alla **Coscienziosità**, forse grazie a una più sofisticata comprensione delle sfumature del linguaggio relative all'organizzazione, alla disciplina e all'attenzione ai dettagli.

Estroversione (Extraversion)




Figura 7: Distribuzione dell'accuratezza per Estroversione

L'istogramma dell'**Estroversione** rivela le distribuzioni più variabili e disperse tra tutti i tratti. Questa caratteristica conferma la difficoltà nella previsione accurata dell'**Estroversione** per tutti i modelli. La variabilità potrebbe essere attribuita alla complessità di questo tratto, che può manifestarsi in modi diversi nel linguaggio scritto, rendendo la sua identificazione più impegnativa per i modelli di linguaggio.

Nevroticismo (Neuroticism)




Figura 8: Distribuzione dell'accuratezza per Nevroticismo

Per il **Nevroticismo**, tutti i modelli mostrano una distribuzione dell'accuratezza spostata verso destra, indicando prestazioni generalmente buone. I modelli **Gemma**, in particolare quelli da **27B**, mostrano distribuzioni più concentrate verso valori di accuratezza più alti. Questo suggerisce che il **Nevroticismo** potrebbe avere manifestazioni linguistiche più facilmente riconoscibili, permettendo ai modelli di identificarlo con maggiore precisione.

Apertura (Openness)




Figura 9: Distribuzione dell'accuratezza per Apertura

Le distribuzioni per l'Apertura (Figura 9) sono più variabili tra i modelli. I modelli Gemma da 27B mostrano distribuzioni più ampie, suggerendo una maggiore capacità di catturare le sfumature di questo tratto. L'Apertura, essendo un tratto legato alla creatività e alla curiosità intellettuale, potrebbe manifestarsi in modi diversi nel linguaggio, richiedendo modelli più sofisticati per una previsione accurata.

In generale, i modelli Gemma, specialmente quelli da 27B, mostrano distribuzioni di accuratezza più favorevoli per la maggior parte dei tratti. Questo conferma le osservazioni precedenti sulla loro superiore capacità di catturare e prevedere le sfumature della personalità. La variabilità nelle distribuzioni tra i diversi tratti sottolinea l'importanza di considerare le prestazioni specifiche per ciascun tratto nella valutazione complessiva dei modelli, piuttosto che basarsi solo su metriche aggregate.

3.7 Heatmap delle Correlazioni

Gemma-2-27b-IQ2_M




Figura 10: Correlazione tra valori attesi e ottenuti - Gemma-2-27b-IQ2_M

Gemma-2-27b-IQ2_M: Questo modello esibisce correlazioni molto elevate per la maggior parte dei tratti. Il **Nevroticismo** emerge come il tratto meglio replicato, con una correlazione di **0.81**. La **Coscienziosità** (**0.57**) e la **Gradevolezza** (**0.55**) mostrano correlazioni moderate, mentre gli altri tratti presentano una precisione inferiore.

Gemma-2-27b-Q3_K_S




Figura 11: Correlazione tra valori attesi e ottenuti - Gemma-2-27b-Q3_K_S

Gemma-2-27b-Q3_K_S: Questo modello mostra prestazioni analoghe al più quantizzato **IQ2_M**, ma con corrispondenze notevolmente più elevate per alcuni tratti. In particolare, il **Nevroticismo** (**0.91**), l'**Apertura** (**0.72**) e la **Coscienza** (**0.70**) presentano correlazioni piuttosto alte. Anche gli altri tratti mostrano correlazioni più soddisfacenti rispetto al modello precedente.

Gemma-2-9b-Q5_K_M




Figura 12: Correlazione tra valori attesi e ottenuti - Gemma-2-9b-Q5_K_M

Gemma-2-9b-Q5_K_M: Questo modello presenta un pattern di correlazioni simile al modello **Q8_0**, ma con valori leggermente inferiori per la maggior parte dei tratti. Il Nevroticismo si conferma il tratto meglio replicato, con una correlazione di **0.91**.

Gemma-2-9b-Q8_0




Figura 13: Correlazione tra valori attesi e ottenuti - Gemma-2-9b-Q8_0

Gemma-2-9b-Q8_0: Questo modello dimostra prestazioni eccellenti nella replicazione del Nevroticismo, con una correlazione di **0.91**. Presenta inoltre buone correlazioni per l'**Estroversione (0.66)** e la **Coscienziosità (0.46)**. L'**Apertura (0.51)** e la **Gradevolezza (0.57)** mostrano correlazioni moderate.

LLaMA-3.1-8B-Q5_K_M




Figura 14: Correlazione tra valori attesi e ottenuti - LLaMA-3.1-8B-Q5_K_M

LLaMA-3.1-8B-Q5_K_M: Questo modello mostra correlazioni generalmente più basse rispetto ai modelli **Gemma**. Il tratto replicato meglio è la **Coscienziosità** con una correlazione di **0.60**. Il **Nevroticismo** presenta una correlazione di **0.54**, mentre gli altri tratti mostrano correlazioni inferiori.

LLaMA-3.1-8B-Q8_0




Figura 15: Correlazione tra valori attesi e ottenuti - LLaMA-3.1-8B-Q8_0

LLaMA-3.1-8B-Q8_0: Migliora leggermente rispetto al modello **Q5_K_M**, con correlazioni più elevate per la **Coscienziosità (0.69)**. Tuttavia, le correlazioni rimangono generalmente più basse rispetto ai modelli **Gemma**.

3.8 Analisi Complessiva delle Prestazioni dei Modelli

Emerge chiaramente la superiorità dei modelli **Gemma** nella replicazione accurata di tutti i tratti, con prestazioni particolarmente notevoli per il **Nevroticismo** e la **Coscienziosità**.

I **modelli Gemma 27B** mostrano generalmente prestazioni superiori rispetto alle loro controparti **9B**, suggerendo che un modello più grande, anche se con una quantizzazione più aggressiva può fornire migliori capacità di comprensione del contesto. Questo potrebbe essere attribuito alla maggiore capacità di questi modelli di cogliere sfumature sottili e complesse del linguaggio associato ai vari tratti di personalità.

I **modelli LLaMA**, sebbene generalmente accurati, mostrano correlazioni più basse rispetto ai modelli **Gemma** per la maggior parte dei tratti. Ciò potrebbe indicare una minor capacità di catturare le sfumature più sottili dei vari tratti di personalità. Tuttavia, è importante notare che questi modelli offrono un enorme vantaggio in termini di velocità di inferenza, che li rendono assolutamente preferibili in scenari dove la rapidità di elaborazione è cruciale.

L'**Estroversione** si conferma come il tratto più sfidante da replicare in modo consistente per tutti i modelli. Questa difficoltà potrebbe essere dovuta alla natura complessa di questo tratto, che può manifestarsi in modi diversi nel linguaggio scritto, al contrario, il **Nevroticismo** emerge come il tratto più facilmente replicabile, con correlazioni molto alte per la maggior parte dei modelli. Questo suggerisce che il linguaggio associato al Nevroticismo potrebbe avere caratteristiche più distintive e facilmente riconoscibili per i modelli di linguaggio.

3.9 Impatto della Quantizzazione sulle Prestazioni

L'analisi delle heatmap rivela anche l'impatto delle diverse tecniche di quantizzazione sulle prestazioni dei modelli:

- La quantizzazione a **3 bit (Q3_K_S)** nel modello **Gemma-2-27b** offre le performance migliori in termini di accuratezza. Tuttavia, questo viene a discapito di una maggiore dimensione del modello, che in questo caso si traduce in un overload di risorse computazionali.
- La quantizzazione a **2 bit (IQ2_M)** nel modello **Gemma-2-27b** mostra un leggero degrado delle prestazioni rispetto alla versione **Q3_K_S**, ma mantiene comunque correlazioni forti per la maggior parte dei tratti. Questo suggerisce un buon compromesso tra accuratezza e efficienza computazionale.
- Nei modelli **Gemma 2 9B** e **LLaMA 3.1 8B**, la differenza tra **Q8_0** e **Q5_K_M** è minima, suggerendo che la quantizzazione a 5 bit potrebbe essere sufficiente per questi modelli più piccoli senza significative perdite di prestazioni. Questo risultato è particolarmente interessante per applicazioni che richiedono un equilibrio tra accuratezza e efficienza computazionale.

4 Discussione e Conclusioni

4.1 Sintesi dei Risultati Principali

Questa ricerca ha esplorato l'efficacia di diversi LLM nella generazione e replicazione di tratti di personalità basati sul modello dei Big Five. I risultati ottenuti offrono interessanti spunti sulle capacità e sui limiti degli LLM attuali in questo contesto specifico.

Prestazioni Generali dei Modelli

I modelli **Gemma**, in particolare i 27B, hanno dimostrato prestazioni superiori in termini di accuratezza e una notevole capacità di catturare e riprodurre le sfumature associate ai diversi tratti del modello Big Five.

D'altra parte, i modelli **LLaMA**, sebbene generalmente meno accurati, hanno dimostrato una velocità di inferenza significativamente superiore, suggerendo un potenziale vantaggio in applicazioni che richiedono risposte in tempo reale.

Differenze tra i Tratti di Personalità

È emerso che alcuni tratti di personalità sono più facilmente replicabili rispetto ad altri. Il **Nevroticismo** è risultato essere il tratto più facilmente replicabile, con correlazioni molto elevate nella maggior parte dei modelli. Ciò indica che le **manifestazioni linguistiche** legate al Nevroticismo potrebbero essere **più distintive e riconoscibili** dai modelli di linguaggio.

Al contrario, l'**Estroversione** si è rivelata il tratto più difficile da replicare in modo coerente in tutti i modelli. Questa complessità potrebbe derivare dalla **natura sfaccettata del tratto**, che si esprime in modi diversi nel linguaggio scritto.

Impatto della Quantizzazione

La quantizzazione a **3 bit (Q3_K_S)** nel modello **Gemma-2-27b** ha offerto le migliori prestazioni in termini di accuratezza, ma a costo di una maggiore dimensione del modello e di un conseguente aumento del carico computazionale.

La quantizzazione a **2 bit (IQ2_M)** ha mostrato un leggero degrado delle prestazioni, mantenendo comunque correlazioni forti per la maggior parte dei tratti, suggerendo un buon compromesso tra accuratezza ed efficienza computazionale.

4.2 Implicazioni Teoriche e Pratiche

Comprensione della Personalità negli LLM

La variabilità nelle prestazioni tra diversi tratti suggerisce che gli LLM potrebbero non avere una comprensione uniforme delle caratteristiche della personalità, suggerendo la presenza di potenziali bias nei dati di addestramento dei modelli.

Applicazioni Pratiche

- **Sviluppo di Videogiochi:** La capacità di generare NPC con personalità coerenti e realistiche potrebbe rivoluzionare l'industria dei videogiochi, offrendo esperienze di gioco più immersive e dinamiche.
- **Chatbot e Assistenti Virtuali:** I risultati suggeriscono la possibilità di creare assistenti virtuali con personalità più ricche e coerenti, migliorando l'interazione uomo-macchina in vari contesti.
- **Ricerca Psicologica:** Gli LLM potrebbero essere utilizzati come strumenti per esplorare le manifestazioni linguistiche dei tratti di personalità, offrendo nuove prospettive per la ricerca psicologica.

4.3 Limiti dello Studio e Direzioni Future

Limiti Metodologici

- **Dimensione del Campione:** Sebbene il numero di test effettuati sia significativo, un campione più ampio potrebbe fornire risultati ancora più robusti e generalizzabili.
- **Variabilità del Contesto:** Lo studio si è concentrato sul *"50-item IPIP version of the Big Five Markers"*. Esplorare test più complessi o altri modelli di personalità potrebbe offrire una visione più completa delle capacità degli LLM in questo ambito.
- **Limitazioni Hardware:** La velocità di inferenza dei modelli sono state influenzate dalle limitazioni hardware, in particolare per quanto riguarda il supporto ROCm su Windows per GPU AMD.

Direzioni Future

- **Esplorazione di Altri Modelli di Personalità:** Estendere lo studio ad altri modelli di personalità oltre i Big Five potrebbe offrire una comprensione più completa delle capacità degli LLM in questo ambito.
- **Analisi Linguistica Approfondita:** Un'analisi più dettagliata delle risposte generate potrebbe rivelare pattern linguistici e/o bias specifici associati a diversi tratti di personalità.
- **Fine-tuning Mirato:** Esplorare l'impatto del fine-tuning mirato su dataset specifici per la personalità potrebbe migliorare ulteriormente le prestazioni dei modelli nell'emulazione dei tratti di personalità e nella capacità "attoriale" di un modello di linguaggio.

Bibliografia

- [1] Matthew N. Bernstein. *Perplexity: a more intuitive measure of uncertainty than entropy*. Retrieved 2024-08-28. 2021. URL: <https://mbernste.github.io/posts/perplexity/>.
- [2] Peter F. Brown et al. «The Mathematics of Statistical Machine Translation: Parameter Estimation». In: *Computational Linguistics* 19.2 (1993), pp. 263–311. URL: <https://aclanthology.org/J93-2003.pdf>.
- [3] Tom B Brown et al. «Language models are few-shot learners». In: *arXiv pre-print arXiv:2005.14165* (2020). URL: <https://splab.sdu.edu.cn/GPT3.pdf>.
- [4] gggerganov. *k-quants: Aggiunta di metodi di quantizzazione a 2-6 bit per modelli linguistici di grandi dimensioni*. 2023. URL: <https://github.com/gggerganov/llama.cpp/pull/1684>.
- [5] L. R. Goldberg. «The development of markers for the Big-Five factor structure». In: *Psychological Assessment* 4 (1992), pp. 26–42. URL: <https://doi.org/10.1037/1040-3590.4.1.26>.
- [6] Lewis R. Goldberg et al. «The international personality item pool and the future of public-domain personality measures». In: *International Journal of Personality Psychology* (2006). URL: https://ipip.ori.org/Goldberg_etal_2006_IPIP_JRP.pdf.
- [7] «Next Generation Issue #15». In: *Next Generation* (1996). URL: <https://archive.org/details/nextgen-issue-015/page/n39/mode/2up>.
- [8] Eirini Ntoutsi et al. «Bias in data-driven artificial intelligence systems—An introductory survey». In: *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 10.3 (2020), e1356. URL: <https://onlinelibrary.wiley.com/doi/full/10.1002/widm.1356>.
- [9] S. J. Russell e P. Norvig. *Intelligenza artificiale: un approccio moderno*. Pearson Education, 2010. URL: <https://www.pearson.com/store/p/intelligenza-artificiale-un-approccio-moderno/9788871922541>.
- [10] Deborah R Smith e William E Snell. «Goldberg’s bipolar measure of the Big-Five personality dimensions: reliability and validity». In: *European Journal of Personality* 10.4 (1996), pp. 283–299.
- [11] Martin Thomson e Cory Benfield. *HTTP/2*. RFC 9113. Giu. 2022. DOI: 10.17487/RFC9113. URL: <https://www.rfc-editor.org/info/rfc9113>.

- [12] Ashish Vaswani et al. «Attention is all you need». In: *Advances in Neural Information Processing Systems*. 2017, pp. 5998–6008. URL: <https://arxiv.org/abs/1706.03762>.
- [13] Shunyu Yao et al. *Tree of Thoughts: Deliberate Problem Solving with Large Language Models*. 2023. arXiv: 2305.10601 [cs.CL]. URL: <https://arxiv.org/abs/2305.10601>.

